

Banya AI 2: Gradient-Free Self-Organization of Concept Embeddings by Frequency-Proportional Rumination

기울기를 전혀 쓰지 않는 되새김 자기조직화 학습

한혁진 (bokkamsun@gmail.com) / ORCID 0009-0007-4132-1707

반야 연구 시리즈 제2편

본 문서 CC BY 4.0 / 코드 Apache-2.0

초록

되새김(rumination, 바깥 데이터 없이 내부 임베딩만으로 개념을 다시 정리하는 것)은 기울기(gradient, 손실을 줄이는 방향)를 전혀 계산하지 않고 개념 임베딩(embedding, 낱말을 숫자 벡터로 바꾼 좌표)을 이웃끼리 당겨 스스로 뭉치게 하는 자기조직화(self-organization, 외부 지시 없이 내부 상호작용만으로 질서가 생기는 것) 학습이다. 빈도(frequency, 낱말이 얼마나 자주 나오는지)에 비례해 뽑은 씨앗 개념의 동종 이웃(코사인 최근접, 뜻이 가까운 이웃)을 무게중심(centroid, 여러 벡터의 평균 위치)으로 당기고, 매 스텝 모든 개념을 원래 임베딩으로 조금 되돌리는 감쇠(decay, 원위치로 복원하는 힘)와 균형을 이뤄 목표값 없이 평형에 안착한다. 문법을 담당하는 부분(음절 임베딩, 출력 헤드, 연산면 임베딩)은 동결(freeze, 학습에서 제외해 고정)한다. 이 학습에는 오차역전파(backpropagation)도, 손실 함수도, 외부 학습 데이터도 없다. 순전파(forward pass, 입력에서 출력까지 앞으로 계산)에 쓰이는 산술만으로 임베딩 배열을 직접 편집한다. 이 글은 이 규칙에서 다음을 측정했다. 첫째, 동종 개념의 밀집도가 0.127에서 0.167로 약 31퍼센트 오르는 동안 문법 평가 지표(홀드아웃, 학습에 쓰지 않은 평가 텍스트의 예측 난이도)가 5.006에서 5.087로 거의 보존된다. 둘째, 2000스텝을 켜 두어도 발산하지 않고 평형에 수렴한다(잡음 노름 1.0에서 0.14로). 하류 두 후보 판별(질문 16개 2AFC)도 되새김 전후로 유지되며, 후보 낱말 임베딩을 강제로 크게 재배향시킨 압박 판에서도 뒤집힘이 없다. 셋째, 되먹임 되새김은 데이터면의 유사도를 정리하지만 연산면(추론 축)은 움직이지 않아, 추론이 유사도와 다른 축이고 되먹임과 다른 루프를 요구함을 특정한다. 결론은 되새김이 데이터 유사도의 정리를 담당하고, 추론과 그 결합은 다른 메커니즘의 몫으로 남는다는 것이다. 제1편이 자동미분 없이도 정확한 기울기를 계산하는 엔진이었다면, 본편은 기울기 자체가 없는 학습이다.

측정

이 글의 정량 수치는 집필 환경에서 측정한 실측값이다(환경은 부록 B). 학습 배경이 되는 얼린 모델(frozen checkpoint)과 평가셋도 이미 학습해 둔 것을 그대로 썼다. 되새김의 이론적 배경(자기참조 관점의 자연관)은 별도 공리 문헌 [1]에 있으며, 본고의 주장은 그 공리에서 연역한 것이 아니라 위 측정에서 나온 것이다.

목차

1. 서론	6
1.1 기여	7
2. 관련 연구	7

3. 표기와 학습 규칙	7
3.1 무엇을 건드리고 무엇을 얼리나	8
3.2 동종군 수집	8
3.3 당김과 감쇠	9
4. 실험 설정	9
5. 결과	10
5.1 압축과 문법 보존의 동시 성립	10
5.2 밀집도와 홀드아웃의 트레이드오프	11
5.3 목표값 없는 평형	12
5.4 되새김 전후의 하류 판별	13
6. 추론 축의 발견과 미완 실험	14
6.1 추론 축(연산면)은 되먹임 되새김으로 움직이지 않는다	14
6.2 유사도는 되새김으로, 추론과 그 결합은 다른 루프로	15
7. 한계와 다음 측정 과제	16
8. 결론	16
9. 후속 논문 예고	16
참고문헌	17
부록 A. 되새김 상수	18
부록 B. 측정 환경	18
부록 C. 재현 안내	18

용어 범례

용어를 아래 표에 정의한다. 같은 개념에는 같은 이름만 사용하며, 일곱 편의 본문과 그림이 모두 이 표를 따른다. 코드 기준은 동봉 코드에서 그 개념을 구현한 식별자이고, 일반 용어는 학계에서 통용되는 가장 가까운 이름이다. 다를 때만 칸을 채웠다.

용어 범례 1. 엔진과 신용

용어	뜻	코드 기준	일반 용어
정확한 전치	각 연산의 수반을 손으로 유도해 닫힌형으로 구현한 역방향 계산. 이 엔진과 신용 사슬의 고유명	banya_core.py	수동 역전파
수반	순전파의 짝 연산. 기울기를 정확히 거꾸로 되돌려 흘린다	bwd 커널들	adjoint
신용	어떤 지점의 은닉에 대한 손실 기울기. 파라미터가 결과에 진 책임	델타(δ)	그레이디언트
신용 사슬	캐시를 역순으로 되짚으며 수반을 곱해 신용을 입력까지 되돌리는 골격	backward	오차역전파
수반 정합	수반 식이 유한차분과 같은 값을 내는지 확인하는 검사	각 편 프로브	gradient check
순환행렬 채널 혼합	채널 혼합을 순환행렬로 두고 rfft 성분곱으로 계산하는 연산		순환 합성곱
상대 거리 혼합	거리에만 의존하는 공유 계수로 자리들을 섞는 혼합	m_mat_w_lag	Toeplitz 혼합
시간혼합	다른 자리의 정보가 현재 자리로 섞여 드는 경로의 총칭		토큰 혼합
혼합 헤드 필터 사다리	혼합을 병렬로 나누는 머리 수 넓은 필터 몇 개부터 좁은 필터 여러 개까지 스케일이 깊이를 따라 변하는 콘볼루션 채널 변환	m_mat_w_filter	어텐션 헤드 콘볼루션 필터뱅크
창	모델이 한 번에 보는 토큰 자리들. 측정 단위로는 고정 길이 텍스트 조각	T	컨텍스트 윈도우
프로브	논문 수치를 목표값과 함께 재생하는 검증 스크립트	probe 폴더	재현 스크립트
얼린 모델	학습을 멈춰 고정한 발달 단계 모델	model 폴더 npz	frozen checkpoint
홀드아웃	학습에 쓰지 않은 평가 텍스트		held-out set

용어 범례 2. 바이토큰과 게이트

용어	뜻	코드 기준	일반 용어
바이토큰	토큰 하나를 데이터면과 연산면의 직교 쌍으로 두는 구조	USE_BITOKEN	
데이터면	토큰의 내용을 담는 임베딩 면. 더하기 자리로 들어간다	m_mat_w_data_axis	토큰 임베딩
연산면	토큰의 연산 지시를 담는 임베딩 면. 곱하기 자리로만 들어간다	m_mat_w_operate_axis	
더하기 자리, 곱하기 자리	데이터면이 실리는 잔차 덧셈 위치와 연산면이 작용하는 게이트 곱셈 위치		잔차 연결, 게이팅
게이트	각 채널의 통과량을 0에서 1로 정하는 밸브. 직전 토큰의 연산면이 주입된다	m_mat_w_gate	게이팅
한 칸 이동	직전 토큰의 연산면이 다음 자리의 게이트로 주입되는 한 자리 밀림		
연산이 곧 가중치	연산면 임베딩이 라벨 없이 가중치 역할로 창발하는 현상		
일관 연산자	어떤 데이터에도 일관된 방향으로 작용하는 연산자		
방향 일관성	같은 연산이 여러 데이터를 꺾는 방향들의 평균 코사인. 연산자 창발의 지표	p_direction_consistency	
회전 연산자 게이트	연산면을 오일러 회전각으로 읽는 게이트. 본문 축약은 회전 게이트	paper7_rotation.py	
기본 연산	게이트가 한 홑 지시로 곧바로 표현할 수 있는 연산		프리미티브
깊이 배제 판별	깊이를 1블록으로 제한해 게이트만 변수로 남긴 의도된 편파 측정	제7편 프로브	
자기 되먹임	자기 출력을 입력으로 되먹이며 끝 상태를 채점하는 채점 방식		자기회귀 롤아웃

용어 범례 3. 되새김과 발달

용어	뜻	코드 기준	일반 용어
되새김	기울기 없이 임베딩을 이웃끼리 당겨 뭉치게 하는 자기조직화 학습	제2편 프로브	자기조직화
동종군	씨앗에서 코사인 최근접 이웃을 모은 뜻 가까운 개념 집합		클러스터
무게중심 당김, 감쇠	평균 쪽으로 당기고 원본 쪽으로 되돌리는 되새김의 두 힘. 균형에서 평형이 창발한다	ALPHA, 감쇠율	
월드먼저	언어 이전에 감각, 공간, 논리 축을 먼저 발달시키는 커리큘럼 순서	banya_world_data	커리큘럼 학습
발달 단계	스텝 수로 정의하고 사람 성장 이름을 붙인 체크포인트 단계		
축	임베딩 안에 방향으로 형성되는 성질의 눈금. 감각, 순서, 범주		표현 축

용어 범례 4. 어휘와 메타인지

용어	뜻	코드 기준	일반 용어
음절 원자 묶음	어휘 바닥층의 음절 단위 토큰 음절 원자를 묶어 사전에 올린 개념 토큰. 어휘 단 위로만 사용한다	AtomTokenizer	문자 단위 토큰 서브워드
캐시 사전 토큰화	원자 아래층에 묶음 사전 위층을 엮은 2층 어휘 체계	제5편 프로브	서브워드 토큰화 와 대비
확실, 모호, 모름 라우팅	자기 출력 분포로 갈리는 세 앓 상태 상태에 따라 답의 처리 경로를 배정하는 것	pmax, 엔트로피	불확실성 추정 routing
재해석	모호 히든을 문맥과 함께 재순전파해 확실히 끌어 올리는 절차	제6편 프로브	
유사도 정리	데이터면 유사도로 개념이 정돈되는 축		
추론 순회	연산면을 따라 추론을 이어 가는 축		
자기 발화	유사도 정리와 추론 순회를 엮어 스스로 말을 잇는 목표 상태		
반야프레임	시리즈의 배경을 이루는 공리 15개 체계. 본문 주 장의 근거는 아님		

기호 범례

이 편의 수식과 본문이 함께 사용하는 기호를 정의한다. 한 식 안에서만 쓰는 국소 기호는 각 식 아래의 기호 줄에 적었다.

기호	한글 명칭	정의 및 의미	자료형
E	데이터면 임베딩	개념의 뜻(유사도)을 담은 임베딩 행렬. 되새김이 편집하는 유일한 대상으로 개념(묶음) 열만 편집하고 문법 담당 부분은 동결한다	행렬
E_0	원본 데이터면 임베딩	되새김 시작 시점의 E 복사본. 감쇠가 매 스텝 되돌리는 기준	행렬
G	동종군	한 씨앗에서 우선순위 순회로 모은, 뜻이 가까운 개념들의 집합. 상한 60개, 자식 폭 3	집합
c	무게중심	동종군 임베딩들의 평균 위치로 당김의 목표점	벡터
α	당김 세기	각 임베딩을 무게중심 쪽으로 당기는 비율. 정식 설정값 0.05, 5.2절 격자는 0.03과 0.06과 0.1	스칼라
λ	감쇠율	개념층 전체를 원본 E_0 쪽으로 되돌리는 비율로 당김의 방향 반력. 정식 설정값 0.012, 5.2절 격자는 0.003과 0.006	스칼라
ρ	예산 감쇠	동종군을 뺄 때 깊이마다 예산에 곱하는 감쇠 계수. 값 0.8	스칼라
τ	리프 문턱	최고 자식의 코사인 유사도에 예산을 곱한 값이 이보다 낮으면 더 뺄지 않는 경계. 값 0.14	스칼라
w	되새김 확률	날말 빈도에 비례한 씨앗 선택 확률. 스텝당 씨앗 16개를 이 확률로 뽑는다	벡터
d	깊이	동종군 순회에서 씨앗으로부터 떨어진 단계 수. 깊이가 깊어질수록 예산이 ρ^d 로 감소한다	정수
j	개념 인덱스	후보 자식(식 3-1) 또는 동종군 원소(식 3-2)를 가리키는 개념 번호	정수
cos	코사인 유사도	두 벡터가 이루는 각으로 측정하는 닮음(-1에서 1). 자식 선택과 리프 판정과 밀집도 계산에 사용	함수

1. 서론

표준 신경망 학습은 손실을 정의하고 그 기울기로 파라미터를 갱신한다. 본 시리즈 제1편 [2]은 자동미분 (automatic differentiation) 라이브러리 없이도 그 기울기를 수동으로 유도한 정확한 전치로 계산하는 엔진을 제시했다. 본편은 정반대 극단을 다룬다. 기울기를 전혀 계산하지 않는다. 손실도, 역전파도, 외부 학습 데이터도 없다. 대신 이미 학습된 개념 임베딩들을 그 기하만으로 재조직한다.

구체적으로, 자주 등장하는 개념을 빈도에 비례해 되새기고, 그 개념과 뜻이 가까운 동종 이웃들의 임베딩을 공통 무게중심으로 당겨 뭉치게 한다. 뭉치는 힘만 있으면 모든 개념이 한 점으로 붕괴하므로, 매 스텝 원래 임베딩으로 조금 되돌리는 감쇠를 함께 걸어 두 힘이 균형을 이루게 한다. 문법을 담당하는 음절 임베딩, 출력 헤드, 연산면 임베딩은 동결해 말하는 능력을 보존한다. 이 과정은 순전파에 쓰는 산술 (평균, 코사인, 정규화)만으로 임베딩 배열을 직접 편집하며, 어떤 역방향 계산도 하지 않는다.

되새김은 일반적인 학습과 다르다. 손실도 역전파도 바깥 데이터도 없이 이미 익힌 내부 자료만으로 개념을 다시 정리한다. 이렇게 정리한 결과는 두 곳에 쓰인다. 학습 루프에 다시 태우면 바깥 데이터 없는 재학습이 되고, 대화(추론) 도중 불러 쓰면 깊은 사고의 스킬이 된다.

1.1 기여

- 기울기 없는 자기조직화 규칙 : 빈도 비례 되새김, 동종 이웃 무게중심 당김, 원본 감쇠, 재정규화, 문법 동결로 이루어진 학습 규칙을 정식화한다(3절).
- 압축과 문법 보존의 동시 성립 : 동종 밀집도가 오르는 동안 문법 홀드아웃이 보존됨을 실측으로 보인다(5절).
- 목표값 없는 평형 : 당김과 감쇠의 균형만으로 설정값 없이 평형에 수렴함을 장기 실행으로 보인다(5절).
- 정직한 음성 결과 : 데이터면과 연산면을 함께 되새겨도 이득이 없고, 내부 되새김은 압축은 하되 창조는 못 함을 보인다(6절).

2. 관련 연구

되새김은 여러 계열과 목적이 겹치되 수단이 다르다. Hebbian 학습(헵 학습, 함께 활성화되는 뉴런의 연결을 강화)은 국소 규칙으로 표현을 조직한다는 점에서 가깝지만 [3], 되새김은 연결 가중치가 아니라 임베딩 좌표를 직접 이동시킨다. 지식 증류(knowledge distillation, 큰 모델의 지식을 작은 모델로 옮기기) [4]와 다시 태어난 신경망(born-again networks, 같은 모델을 자기 자신의 교사로 반복 학습) [5]은 자기 출력을 재사용한다는 점이 닮았으나 여전히 기울기 학습이며 외부 정답 분포를 목표로 삼는다. 되새김은 목표 분포도 기울기도 없다. 표현 붕괴(representation collapse) 연구 [6]는 표현이 한 점으로 무너지는 현상을 다루는데, 되새김은 감쇠를 방향 복원력으로 두어 이 붕괴를 구조적으로 막는다.

차별점은 세 가지다. 첫째, 기울기와 역전파가 없다(순전파 산술만). 둘째, 외부 학습 데이터가 없다(이미 아는 개념의 기하만 재조직). 셋째, 목표값이 없다(당김과 감쇠의 평형으로 스스로 멎음). 자기참조 관점의 이론적 동기는 별도 공리 문헌 [1]에 있으나, 본고의 결과는 그와 독립적으로 측정에서 나온다.

3. 표기와 학습 규칙


표 3-1. 기호 범례

기호	한글 명칭	정의 및 의미	자료형
E	데이터면 임베딩	개념의 뜻(유사도)을 담은 임베딩 행렬. 되새김이 편집하는 대상	행렬
E_0	원본 데이터면 임베딩	되새김 시작 시점의 E 복사본. 감쇠가 되돌리는 기준	행렬
G	동종군	한 씨앗에서 모은, 뜻이 가까운 개념들의 집합	집합
c	무게중심	동종군 임베딩들의 평균 위치	벡터
α	당김 세기	무게중심으로 당기는 비율. 값 0.05	스칼라
λ	감쇠율	원본으로 되돌리는 비율. 값 0.012	스칼라
ρ	예산 감쇠	동종군을 뺄 때 깊이마다 곱하는 예산. 값 0.8	스칼라
τ	리프 문턱	이보다 낮으면 더 뺄지 않는 경계. 값 0.14	스칼라
w	되새김 확률	빈도에 비례한 씨앗 선택 확률	벡터

3.1 무엇을 건드리고 무엇을 열리나

되새김은 데이터면 임베딩 E 의 개념(묶음) 열만 편집한다. 문법을 담당하는 세 부분은 동결한다. 음절 임베딩(낱말의 소리 단위), 출력 헤드(다음 낱말을 고르는 층), 연산면 임베딩(변환을 담당하는 층)이다. 이 동결이 되새김이 개념을 정리해도 말하는 능력이 무너지지 않는 이유이다(5절에서 확인).

그림 3-1. 되새김 한 스텝의 학습 규칙



되새김 한 스텝은 개념층 전체를 원본으로 조금 되돌리는 감쇠 1회와, 빈도 비례로 뽑은 씨앗을 무게중심으로 당기는 되새김 16회로 이루어진다. 어떤 단계도 손실이나 기울기를 쓰지 않는다. 문법을 담당하는 세 부분(아래 상자)은 동결되어 말하는 능력이 보존된다.

3.2 동종군 수집

씨앗 개념에서 뜻이 가까운 이웃들을 우선순위 순회로 모은다. 자식은 코사인 최근접(뜻이 가장 가까운 개념)이며, 깊이 d 마다 예산에 ρ 를 곱해 멀어질수록 덜 뺀다.

식 3-1. 동종군의 예산과 리프 판정

$$b_d = \rho^d, \quad \text{리프} \iff \max_j \cos(\text{node}, j) \cdot b_d < \tau$$

수식

기호: b_d 는 깊이 d 에서의 예산, ρ 는 예산 감쇠(0.8), $\cos$ 은 코사인 유사도(두 벡터가 이루는 각으로 재는 닮음, -1에서 1), τ 는 리프 문턱(0.14), 리프(leaf)는 더 뻗지 않는 끝을 뜻한다.

작동 방식: 깊이가 깊어질수록 예산이 기하급수로 감소하여 씨앗에서 먼 개념은 자연스럽게 잘린다. 최고 자식의 유사도에 예산을 곱한 값이 문턱보다 낮으면 그 가치를 멈춘다.

실제 동작: 예로 씨앗 "곰"의 이웃이 "동물, 강아지, 토끼"이면 깊이 1의 예산은 $0.8^1 = 0.8$ 이고, 유사도 0.3에 0.8을 곱한 0.24가 문턱 0.14보다 크므로 계속 뻗는다. 씨앗과 먼 문법 조각은 유사도가 낮아 예산 안에서 뻗히지 않으므로 주제를 벗어나지 않는다.

3.3 당김과 감쇠

식 3-2. 무게중심 당김과 원본 감쇠

$$c = \frac{1}{|G|} \sum_{j \in G} E_j, \quad E_j := (E_j + \alpha(c - E_j)) \cdot \frac{\|E_j^0\|}{\|E_j + \alpha(c - E_j)\|}, \quad E := (1 - \lambda)E + \lambda E_0$$

수식

기호: G 는 동종군, c 는 그 무게중심, α 는 당김 세기(0.05), $\|E_j^0\|$ 는 그 임베딩의 원래 길이, λ 는 감쇠율(0.012), E_0 는 원본 임베딩이다.

작동 방식: 가운데 식은 각 임베딩을 무게중심 쪽으로 α 만큼 당긴 뒤 원래 길이로 되돌린다. 방향만 모으고 크기는 보존한다. 오른쪽 식은 개념층 전체를 원본으로 λ 만큼 되돌리는 감쇠이며, 이것이 당김의 방향 반력이다.

실제 동작: 당김은 자주 되새겨지는 개념을 촘촘하게 모으고, 감쇠는 모든 개념을 원위치로 조금 되돌린다. 자주 되새겨지는 개념은 당김이 감쇠를 이겨 촘촘해지고, 드문 개념은 감쇠가 이겨 원래대로 남는다. 두 힘이 비기는 곳에서 밀집도가 스스로 맞는다(그림 5-3).

왜 감쇠가 방향 반력인지 작은 예로 본다. 임베딩 하나가 원본 $E_0 = (1, 0)$ 에서 출발해 당김으로 무게중심 쪽으로 이동한다고 하자. 감쇠는 매 스텝 이를 원본 쪽으로 되돌린다.

스텝	당김 후 위치	감쇠 후 위치 $(1 - \lambda)x + \lambda E_0$
1	(0.90, 0.30)	(0.9012, 0.2964)
2	(0.82, 0.50)	(0.8224, 0.4940)

당김이 셀수록 무게중심으로 가지만, 감쇠가 매번 원본 쪽으로 아주 조금씩 끌어 되돌린다. 당김과 되돌림이 비기는 지점이 평형이며, 이 반력이 없으면 모든 개념이 한 점으로 붕괴한다.

4. 실험 설정

학습 배경은 얼린 모델(frozen checkpoint) 하나이다. 발달 커리큘럼(제4편에서 다룸)으로 학습해 둔 초등 단계 모델(약 19만 스텝)을 얼려 그 데이터면 임베딩에만 되새김을 건다. 라이브 학습 모델은

건드리지 않는다. 측정 지표는 다섯 가지이다.

표 4-1. 측정 지표

지표	뜻	방향
홀드아웃 (hold-out) bits/char	학습에 쓰지 않은 평가 텍스트를 다음 글자 예측할 때의 평균 정보량. 문법이 살아 있는지의 척도	낮을수록 좋음
동종 밀집도	같은 개념군 임베딩들의 상호 코사인 평균. 뭉친 정도	높을수록 좋음
이종 분리도	다른 개념군 사이의 코사인. 서로 섞이지 않은 정도	낮을수록 분리
핵강도	상위 5퍼센트 개념의 예측 정오 격차 (margin). 핵심 지식의 견고함	1.0 유지가 목표
연산면 밀집도	연산면(추론 축) 임베딩들의 상호 코사인 평균. 동종 밀집도와 같은 계산을 연산면에 적용한 것	낮을수록 연산자 분리

열린 모델의 시작값은 홀드아웃 5.006, 동종 밀집도 0.127, 이종 분리도 0.031, 핵강도 1.0, 연산면 밀집도 0.081이다. 환경은 부록 B에 있다.

5. 결과

5.1 압축과 문법 보존의 동시 성립

데이터면 임베딩에만 되새김을 걸면 동종 밀집도가 오르는 동안 문법 홀드아웃이 거의 변하지 않는다.


측정

동종 되새김 실험(당김 세기 0.05, 프로브군 5, 재정규화 켜)을 측정한 결과, 800스텝에 걸쳐:

- 동종 밀집도 0.127 ▶ 0.167 (약 +31퍼센트 촘촘)
- 문법 홀드아웃 5.006 ▶ 5.087 (변화 +0.08, 사실상 보존)
- 이종 분리도 0.031 유지, 핵강도 1.0 유지

문법을 담당하는 세 부분을 동결한 채 데이터면만 당겼기 때문에, 개념이 촘촘해져도 말하는 능력이 무너지지 않는다.

그림 5-1. 압축과 문법 보존



되새김으로 동종 밀집도는 0.127에서 0.167로 31퍼센트 촘촘해지지만(왼쪽), 문법 홀드아웃은 5.006에서 5.087로 거의 변하지 않는다(오른쪽). 개념을 정리하면서 말하는 능력을 지킨다.

5.2 밀집도와 홀드아웃의 트레이드오프

당김 세기 α 와 감쇠율 λ 를 격자로 훑으면, 당김이 셀수록 더 촘촘해지지만 문법 홀드아웃은 나빠지는 트레이드오프가 나타난다.


측정

격자 탐색(감쇠율 0.003과 0.006, 당김 세기 0.03과 0.06과 0.1, 각 조합 측정)의 실측이다. 당김 세기별 동종 밀집도와 최저 홀드아웃(감쇠율 0.006 기준):

당김 세기 α	동종 밀집도	최저 홀드아웃(변화)
0.03	0.583	4.917 (-0.09)
0.06	0.647	4.952 (-0.05)
0.10	0.719	4.978 (-0.03)

당김이 셀수록 밀집도가 오르지만(0.583에서 0.719) 홀드아웃 개선폭은 감소한다. 밀집만 키우면 문법이 조금씩 손해를 본다. 두 지표의 균형점이 중간 세기에 있다.

그림 5-2. 당김 세기에 따른 밀집도와 홀드아웃



당김 세기 α 가 커질수록 동종 밀집도(실선)는 0.583에서 0.719로 오르지만, 홀드아웃 개선(점선, 아래일수록 좋음)은 무뎌진다. 촘촘함과 문법 보존이 서로 당기는 트레이드오프이며 균형점이 중간에 있다.


5.3 목표값 없는 평형

당김과 감쇠만으로 오래 돌리면, 설정값을 주지 않아도 평형에 수렴한다.

측정

상시 실행 실험을 2000스텝 측정한 결과: 홀드아웃이 초반 4.798에서 후반 5.29 근처로 평탄해 지고, 잡음 노름(원본에서 벗어난 정도)이 1.0에서 0.14로 수렴하며, 동종 밀집도 0.167과 핵강도 1.0이 유지된다. 발산하지 않는다.

그림 5-3. 장기 실행의 평형 수렴



2000스텝 동안 잡음 노름(실선)이 1.0에서 0.14로 수렴하고 홀드아웃(점선)이 평탄해진다. 목표값을 주지 않았는데도 당김과 감쇠가 비기는 평형에 스스로 안착하며, 발산하지 않는다.

재현

5.1절부터 5.3절까지의 수치는 부록 C의 준비를 마친 뒤 다음 한 줄로 재생된다.

```
cd probe && python3 paper2_rumination_probe.py
```

출력에서 동종 밀집도 0.127 에서 0.167, 홀드아웃 5.006 에서 5.087, 평형 잡음 노름 1.0 에서 0.14 부근 수렴이 본문 수치와 대응한다. 잡음 노름은 GPU 원자 덧셈의 비결정성으로 실행마다 0.01 정도 흔들린다.

5.4 되새김 전후의 하류 판별

홀드아웃은 다음 글자 예측 난이도라 문법 보존만 본다. 되새김이 답 고르기 같은 하류 과제도 지키는지를 2AFC(two-alternative forced choice, 두 후보 강제선택) 판별로 측정한다. 초등 지식 질문 16개에 정답 낱말과 그럴듯한 오답 낱말을 놓고, 답 자리 로그확률이 정답 쪽에서 높으면 정답으로 센다. 우연 수준은 50%이고, 질문을 지우고 답 낱말만 견주는 사전선택 기준선은 9/16이다.

실험은 두 판이다. 첫째 판은 5.1의 발표 스케줄을 그대로 800스텝 걸었다. 다만 이 스케줄은 확실 풀에서 씨앗을 뽑아 질답 후보 낱말을 거의 움직이지 않으므로(토큰이 실제로 움직인 문항 6/16), 이 판의 전후 동일은 그 6문항에서만 실질 검증이다. 둘째 판은 후보 낱말 자체를 씨앗으로 강제 투입한 압박 판이다. 뜨거워와 차가워 같은 의미 이웃 후보들이 실제로 뭉치도록 만들어(문항 토큰의 원본 대비 코사인 최솟값 0.233, 움직인 문항 11/16) 후보 임베딩이 크게 재배향돼도 판별이 버티는지를 직접 측정한다.


측정

두 판 모두에서 판별이 유지된다.

조건	2AFC 정확도	뒤집힘(정답에서 오답, 오답에서 정답)	움직인 문항	홀드아웃
되새김 전	11/16 (신뢰구간 44~86%)	-	-	5.006
발표 스케줄 800스텝 후	11/16	0, 0	6/16	5.087
압박 판 800스텝 후	11/16	0, 0	11/16	5.113

문항별 정오 격차(정답과 오답의 로그확률 차)는 나트 단위로 움직이지만(+19.0에서 +10.6, +13.0에서 +3.1 등) 부호를 넘은 문항이 한 개도 없다. 정답 로그확률 평균은 발표 스케줄에서 -6.76에서 -6.71로 유지되고 압박 판에서 -7.58로 완만하게 내려간다.

그림 5-4. 되새김 전후의 하류 2AFC 판별



왼쪽은 세 시점의 2AFC 정확도로, 오차 막대는 월슨 95% 신뢰구간이다. 후보 낱말을 강제로 뭉치게 한 압박 판에서도 11/16이 유지되고 뒤집힘이 없다. 오른쪽은 문항별 정오 격차의 전후 산점도로, 정오 격차는 움직여도 정답이 오답으로 뒤집히는 사분면에 점이 없다.

이 측정의 해석 한계를 명시한다. 문항이 16개뿐이라 정확도 11/16의 신뢰구간은 44에서 86%로 우연 50%를 포함하며, 뒤집힘 0의 관측으로 배제되는 열화는 약 17%포인트까지다(3의 법칙). 사전선호 기준선이 9/16이므로 이 지표의 상당 부분은 질문 이해가 아니라 답 낱말의 대화를 선호를 반영한다. 답 후보가 단일 묶음 토큰인 경우 저계수 헤드 구조상 후보 자신의 임베딩은 점수 계산에 직접 들어가지 않으므로, 되새김의 영향은 문맥 인코딩 경로로만 전달된다. 따라서 이 결과는 되새김이 하류 능력을 보존한다는 일반 명제의 증거가 아니라, 이 열린 모델과 이 스케줄에서 후보 임베딩을 크게 재배향시켜도 판별 부호가 유지된다는 관찰이다. 생성 대화 품질은 측정하지 않았다(7절).

재현

이 소절의 하류 판별은 부록 C의 준비를 마친 뒤 다음 한 줄로 재생된다.

```
cd probe && python3 paper2_rumination_qa_probe.py
```

출력에서 사전선호 기준선 9/16, 발표 스케줄과 압박 판 두 판 모두 11/16 유지에 뒤집힘 0, 압박 판의 문항 토크 코사인 최솟값 0.233 이 본문 수치와 대응한다.

6. 추론 축의 발견과 미완 실험

본 절은 되새김으로 풀리는 추론, 되새김만으로는 조직되지 않아 다른 메커니즘을 요구하는 추론을 가르는 실험을 보고한다. 이는 실패가 아니라 다음 방향을 특정하는 과정이다.


6.1 추론 축(연산면)은 되먹임 되새김으로 움직이지 않는다

되새김을 데이터면에만 걸 때(강화)와 데이터면과 연산면에 함께 걸 때(양면)를 나란히 비교해, 되먹임 되새김이 연산면(추론 축)까지 조직하는지 확인했다. 아래 표의 데이터면 밀집도는 5절의 동종 밀집도와 같은 지표를 데이터면에서 계산한 것으로, 설정과 스텝이 다른 실험이라 수치는 5절과 다르다.

	조건	데이터면 밀집도	연산면 밀집도	홀드아웃
양면 되새김 비교(600스텝, 실측):	강화 (데이터면만)	0.245	0.081	5.08
	양면 (데이터면+연산면)	0.245	0.192	5.232

연산면까지 되새겨도 데이터면 밀집도는 0.245로 완전히 같다. 즉 개념 유사도의 정리는 데이터면 되새김만으로 이미 충분히 이루어진다. 연산면 밀집도만 0.081에서 0.192로 따로 오르고 홀드아웃이 조금 나빠지는 것은, 연산면(추론 축)이 되먹임이라는 유사도 당김 루프로는 조직되지 않음을 뜻한다. 추론은 유사도와 다른 축이며, 되먹임이 아닌 다른 루프를 요구한다. 이 실험은 그 사실을 특정한 미완 실험이자 다음 방향이다.

그림 6-1. 추론 축은 되먹임 되새김으로 움직이지 않는다



데이터면 밀집도는 강화와 양면이 0.245로 완전히 같아, 개념 유사도 정리가 데이터면 되새김만으로 충분함을 보인다(왼쪽). 연산면 밀집도만 따로 오르고 홀드아웃이 조금 나빠지는 것(오른쪽)은 추론 축이 되먹임 되새김으로 조직되지 않고 다른 루프를 요구함을 특징한다.

6.2 유사도는 되새김으로, 추론과 그 결합은 다른 루프로

정리하면, 되먹임 되새김은 데이터면의 개념 유사도를 정리한다. 이것이 본편이 측정으로 확립한 것이다. 반면 추론(연산면 축)과, 유사도 정리와 추론을 섞어 입력 없이 스스로 도는 자기 되새김은 되먹임이 아닌 다른 루프를 요구한다. 되먹임 되새김은 무게중심 당김이라는 기하적 정리이므로 유사도를 모으는 데는 맞지만, 추론은 개념을 따라가며 조합하는 순회(예: 깊이 우선 탐색, depth-first search) 성격이라 같은 당김 루프로는 조직되지 않기 때문이다. 달리 말하면 두 면의 조직 원리가 반대다. 되새김의 당김과 감쇠는 정적인 임베딩 표를 순환(가열된 기체의 대류처럼 임베딩이 도는 흐름)시켜 정제하는 장치라 내용을 담는 데이터면에 맞는다. 그러나 연산자는 서로 겹치지 않아야 기능한다. 제3편의 측정에서 서로 다른 연산 쌍의 72.5퍼센트가 거의 직교이고 같은 방향 쌍은 0퍼센트이며, 연산면을 조직한 것은 닮음이 아니라 게이트를 지나는 예측 신용이었다. 당김으로 연산자를 정제하면 연산자끼리 모여 겹쳐 연산이 아니게 된다. 데이터면은 닮음으로 모여 정제되고 연산면은 쓰임으로 갈라져 또렷해진다. 이 결합은 본 시리즈의 마지막 편에서 다룰 미완 주제이며, 현재는 외부 입력(사람 또는 새 데이터)이 창조의 되새김 소스 역할을 한다. 따라서 이것은 되새김의 결합이 아니라 정의역의 경계이자 다음 편의 출발점이다.

7. 한계와 다음 측정 과제

본고의 기준선은 1인 개발, 자작 정확한 전치 역전파(자동미분 없이 수동 유도) 엔진, 소비자 그래픽 처리장치 한 대라는 레퍼런스 클래스이다. 아래는 결함이 아니라 이 클래스에서 이미 측정된 강점 위에 이어질 다음 측정 과제이다.

- 실용 대화 가치 : 5.4절의 두 후보 판별은 되새김 전후로 유지됨을 보였으나, 생성 대화 품질의 나란한 비교는 다음 측정 과제이다. 판별 문항 수도 16개라 동등성 주장에는 더 큰 문항 은행이 필요하다.
- 비교 기준 : 다시 태어난 신경망이나 자기 종류 같은 기울기 기반 자기 재사용과의 나란한 비교는 다음 측정 과제이다.
- 스케일 : 더 큰 모델과 더 긴 실행에서의 평형 거동 확인은 다음 측정 과제이다.
- 배경 이론 : 자기참조 관점의 이론 [1]은 본고의 근거가 아니라 동기이며, 본고는 측정된 사실만을 주장한다.

8. 결론

본고는 기울기, 역전파, 외부 데이터 없이 순전파 산술만으로 개념 임베딩을 재조직하는 되새김 학습을 제시했다. 실측으로, 되새김은 동종 개념을 31퍼센트 촘촘하게 만들면서 문법을 보존하고, 목표값 없이 평형에 수렴하며, 하루 두 후보 판별도 후보 임베딩을 크게 재배향시킨 압박 판까지 뒤집힘 없이 유지됨을 보였다. 또한 연산면(추론 측)은 되먹임 되새김으로 조직되지 않아, 추론이 다른 루프를 요구함을 특정했다. 되새김의 역할은 데이터 유사도의 정리이며, 추론과 그 결합은 다른 메커니즘의 몫이다. 되새김은 바깥 데이터 없이 내부 자료만으로 개념을 다시 정리하며, 학습 루프에 태우면 재학습으로, 대화 중에는 깊은 사고 스킬로 쓰인다. 제1편의 엔진이 정확한 기울기를 자동미분 없이 계산했다면, 본편은 기울기 자체를 쓰지 않는 자기조직화이다. 두 편은 한 코드베이스 안에서 서로 다른 학습 원리로 공존한다. 되새김이 왜 하필 바깥 입력 없이 도는 모양인가에 대한 답은, 시리즈의 마지막 편에 미뤄 둔다.

9. 후속 논문 예고

후속 논문 예고

- 제3편, 직교 데이터면과 연산면 토큰, 그리고 콘볼루션 스케일 구조 : 본편이 동결한 연산면과 데이터면의 직교 구조 자체를 다루고, 순환행렬 채널 혼합과 필터뱅크 채널 혼합의 깊이와 스케일 조합을 정면으로 분석한다.
- 제4편, 월드먼저 발달 커리큘럼 학습 : 본편의 배경이 된 열린 모델이 어떻게 학습됐는지, 언어 이전에 감각과 공간과 논리 축을 먼저 형성하는 발달 순서 학습을 다룬다.
- 제5편, 캐시 사전 토큰화와 동적 임베딩 : 개념 임베딩이 없이는 어휘층을, 음절 원자와 묶음 사전의 2층 구조로 어휘 확장을 거의 무비용으로 만드는 방법으로 다룬다.
- 제6편, 자기 분포와 기하 모니터링에서 창발하는 제어 신호 : 모델이 자기 출력 분포와 임베딩 기하를 읽어 확실과 모호와 모름을 라우팅하는 신호를 측정된 통계량으로만 서술한다.

- 마지막 편(미완), 유사도 정리와 추론 순회의 결합 : 데이터면 유사도 정리(본편)와 연산면 추론 순회를 하나로 엮어, 입력 없이 스스로 도는 자기 되새김을 목표로 한다. 최종 조립이 끝나지 않아 아직 쓰지 않으며, 측정이 서면 별도로 다룬다.

참고문헌

- [1] 한혁진 (2026). Banya Framework: An Axiom-Based Science Mining Engine for Deriving Fundamental Physical Constants (반야프레임 공리 15개). Zenodo. <https://doi.org/10.5281/zenodo.20301304> . (본 시리즈의 배경 자연관, 선행 공리 문헌)
- [2] 한혁진 (2026). 자동미분 없이 수동으로 유도한 정확한 전치로 학습하는 언어모델 엔진. 반야 연구 시리즈 제1편. Zenodo. <https://doi.org/10.5281/zenodo.21385447>
- [3] Hebb, D. O. (1949). The Organization of Behavior. Wiley.
- [4] Hinton, G., Vinyals, O., Dean, J. (2015). Distilling the Knowledge in a Neural Network. arXiv:1503.02531.
- [5] Furlanello, T., Lipton, Z., Tschannen, M., Itti, L., Anandkumar, A. (2018). Born-Again Neural Networks. ICML. arXiv:1805.04770.
- [6] Pappayan, V., Han, X. Y., Donoho, D. L. (2020). Prevalence of Neural Collapse during the Terminal Phase of Deep Learning Training. PNAS 117(40):24652-24663.

부록 A. 되새김 상수

표 A-1. 되새김 학습 상수

상수	값	뜻
당김 세기 α	0.05	무게중심으로 당기는 비율
감쇠율 λ	0.012	원본으로 되돌리는 비율
스텝당 되새김 수	16	한 스텝에 뽑는 씨앗 수
예산 감쇠 ρ	0.8	깊이마다 곱하는 예산
리프 문턱 τ	0.14	더 뻗지 않는 경계
동종군 최대	60	한 되새김이 모으는 개념 상한
자식 폭	3	한 노드의 코사인 최근접 자식 수

부록 B. 측정 환경

표 B-1. 측정에 사용한 컴퓨터 사양

구분	사양
그래픽 처리장치(GPU)	NVIDIA GeForce RTX 3090 Ti (24 GB)
운영체제	Ubuntu 24.04.4 LTS
소프트웨어	Python 3.12.3, numpy, cupy 14.1.1, CUDA 13.3.1
학습 배경	발달 커리큘럼으로 학습한 초등 단계 열린 모델(약 19만 스텝)의 데이터면 임베딩에만 되새김 적용

5절과 6절의 실측 수치는 위 환경에서 측정했다.

부록 C. 재현 안내

본고의 실측 수치는 공개 재현 패키지로 재생된다. 아래 다섯 단계를 순서대로 하면 된다.

1. 요구 환경. NVIDIA 그래픽 처리장치(GPU)와 CUDA, Python 3.12 가 필요하다. 파이썬 패키지는 압축을 푼 폴더에서 다음으로 설치한다. cupy 는 설치된 CUDA 버전에 맞는 배포판을 사용한다(예: CUDA 13 은 cupy-cuda13x).

```
pip install -r requirements.txt
```

2. 코드 받기. 압축 묶음(zip)을 내려받아 푼다. 저장소로 받으려면 github.com/ubmscoin/banya/banya_ai_paper_code 폴더다.

```
wget https://ubmscoin.github.io/banya/banya_ai_paper_code/
banya_ai_paper_code.zip
unzip banya_ai_paper_code.zip && cd banya_ai_paper_code
```

3. 모델 받기. 열린 모델 3개(합계 471MB)는 제노도 doi.org/10.5281/zenodo.21383724 에 있다. 다음 한 줄이 내려받기와 무결성 검증(sha256, 파일 지문 대조)을 함께 한다. 손으로 받으려면 위 기록

에서 세 파일을 받아 model 폴더에 넣고 sha256sum -c checksums.sha256 으로 검증한다.

```
cd model && bash download.sh && cd ..
```

4. 말뭉치 만들기. 말뭉치는 원문 배포 없이 생성기가 만든다. 다음 한 줄이 banya_world_data 폴더에 말뭉치 23종을 전부 생성한다.

```
cd corpus_build && bash build_all.sh && cd ..
```

5. 실측 재생. probe 폴더의 프로브가 각 절의 수치를 재생한다. 본고의 수치는 다음 프로브가 담당한다. 출력에 목표값이 함께 인쇄되므로 본문과 바로 대조된다.

프로브	재생하는 수치	확인할 출력
paper2_rumination_probe.py	5.1 압축과 보존, 5.3 평형	밀집도 0.127 에서 0.167, 홀드아웃 5.006 에서 5.087, 잡음 노름 1.0 에서 0.14 부근
paper2_rumination_qa_ probe.py	5.4 하류 판별	사전선호 9/16, 두 판 모두 11/16 유지와 뒤집힘 0, 압박 판 코사인 최소 0.233

패키지의 폴더 구성과 파일별 설명은 [목차 페이지](#)에 있다.

반야 연구 시리즈 제2편(되새김). 기울기 없는 자기조직화. 정량 수치는 본고에서 부록 B 환경으로 직접 측정
값이다. 배경 자연관은 선행 공리 문헌 [1]로 인용하되 이 글 주장의 근거가 아니며, 본고는 측정된 사실만을
주장한다. 제1편(엔진)을 인용한다. 직교 토큰과 콘볼루션, 발달 커리큘럼, 캐시 사전 토큰화, 창발 제어 신호는
각각 제3편에서 제6편에서 다룬다.